10 | 浏览器: 一个浏览器是如何工作的? (阶段一)

2019-02-09 winter



对于前端开发来说,我们平时与浏览器打交道的时间是最多的。可浏览器对前端同学来说更多像一个神秘黑盒子的存在。我们仅仅知道它能做什么,而不知道它是如何做到的。

在我面试和接触过的前端开发者中,**70%**的前端同学对这部分的知识内容只能达到"一知半解"的程度。甚至还有一部分同学会质疑这部分知识是否重要:这与我们的工作相关吗,学多了会不会偏移前端工作的方向?

事实上,我们这里所需要了解的浏览器工作原理只是它的大致过程,这部分浏览器工作原理不但是前端面试的常考知识点,它还会辅助你的实际工作,学习浏览器的内部工作原理和个中缘由,对于我们做性能优化、排查错误都有很大的好处。

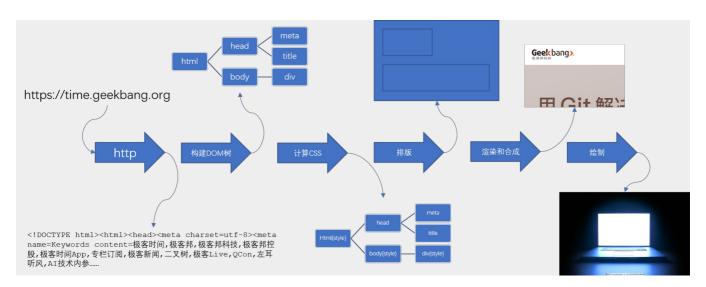
在我们的课程中,我也会控制浏览器相关知识的粒度,把它保持在"给前端工程师了解浏览器"的水准,而不是详细到"给浏览器开发工程师实现浏览器"的水准。

那么,我们今天开始,来共同思考一下。一个浏览器到底是如何工作的。

实际上,对浏览器的实现者来说,他们做的事情,就是把一个URL变成一个屏幕上显示的网页。 这个过程是这样的:

- 1. 浏览器首先使用HTTP协议或者HTTPS协议,向服务端请求页面;
- 2. 把请求回来的HTML代码经过解析,构建成DOM树:

- 3. 计算DOM树上的CSS属性:
- 4. 最后根据CSS属性对元素逐个进行渲染,得到内存中的位图;
- 5. 一个可选的步骤是对位图进行合成,这会极大地增加后续绘制的速度:
- 6. 合成之后,再绘制到界面上。



我们在开始详细介绍之前,要建立一个感性认识。我们从**HTTP**请求回来开始,这个过程并非一般想象中的一步做完再做下一步,而是一条流水线。

从HTTP请求回来,就产生了流式的数据,后续的DOM树构建、CSS计算、渲染、合成、绘制,都是尽可能地流式处理前一步的产出:即不需要等到上一步骤完全结束,就开始处理上一步的输出,这样我们在浏览网页时,才会看到逐步出现的页面。

首先我们来介绍下网络通讯的部分。

HTTP协议

浏览器首先要做的事就是根据**URL**把数据取回来,取回数据使用的是**HTTP**协议(实际上这个过程之前还有**DNS**查询,不过这里就不详细展开了。)

我先来了解下HTTP的标准。

HTTP标注由IETF组织制定,跟HTTP相关的标准主要有两份:

1. HTTP1.1 https://tools.ietf.org/html/rfc2616

2.HTTP1.1 https://tools.ietf.org/html/rfc7234

HTTP协议是基于TCP协议出现的,对TCP协议来说,TCP协议是一条双向的通讯通道,HTTP在TCP的基础上,规定了Request-Response的模式。这个模式决定了通讯必定是由浏览器端首先发起的。

大部分情况下,浏览器的实现者只需要用一个TCP库,甚至一个现成的HTTP库就可以搞定浏览

器的网络通讯部分。HTTP是纯粹的文本协议,它是规定了使用TCP协议来传输文本格式的一个应用层协议。

下面,我们试着用一个纯粹的TCP客户端来手工实现HTTP一下:

实验

我们的实验需要使用telnet客户端,这个客户端是一个纯粹的TCP连接工具(安装方法)。

首先我们运行telnet,连接到极客时间主机,在命令行里输入以下内容:

telnet time.geekbang.org 80

这个时候, TCP连接已经建立, 我们输入以下字符作为请求:

GET / HTTP/1.1

Host: time.geekbang.org

按下两次回车,我们收到了服务端的回复:

HTTP/1.1 301 Moved Permanently

Date: Fri, 25 Jan 2019 13:28:12 GMT

Content-Type: text/html Content-Length: 182

Connection: keep-alive

Location: https://time.geekbang.org/

Strict-Transport-Security: max-age=15768000

<html>

<head><title>301 Moved Permanently</title></head>

<body bgcolor="white">

<center><h1>301 Moved Permanently</h1></center>

<hr><center>openresty</center>

</body>

</html>

这就是一次完整的HTTP请求的过程了,我们可以看到,在TCP通道中传输的,完全是文本。

在请求部分,第一行被称作 request line,它分为三个部分,HTTP Method,也就是请求的"方

法",请求的路径和请求的协议和版本。

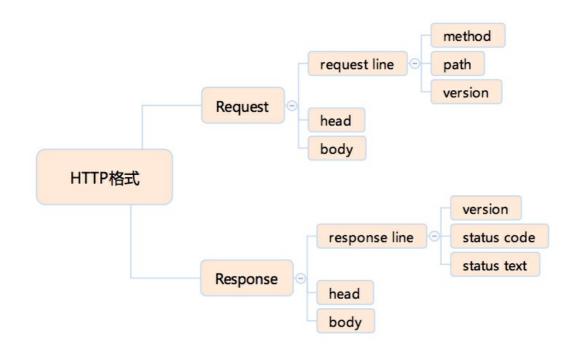
在响应部分,第一行被称作 response line,它也分为三个部分,协议和版本、状态码和状态文本。

紧随在request line或者response line之后,是请求头/响应头,这些头由若干行组成,每行是用冒号分隔的名称和值。

在头之后,以一个空行(两个换行符)为分隔,是请求体/响应体,请求体可能包含文件或者表单数据,响应体则是html代码。

HTTP协议格式

根据上面的分析,我们可以知道HTTP协议,大概可以划分成如下部分。



我们简单看一下,在这些部分中,path是请求的路径完全由服务端来定义,没有很多的特别内容;而version几乎都是固定字符串;response body是我们最熟悉的HTML,我在后面会有专门的课程介绍,这里也就不多讲了。

下面我们就来逐个给你介绍其它部分。

HTTP Method (方法)

我们首先来介绍一下request line里面的方法部分。这里的方法跟我们编程中的方法意义类似,表示我们此次HTTP请求希望执行的操作类型。方法有以下几种定义:

- GET
- POST

- HEAD
- PUT
- DELETE
- CONNECT
- OPTIONS
- TRACE

浏览器通过地址栏访问页面都是GET方法。表单提交产生POST方法。

HEAD则是跟GET类似,只返回请求头,多数由JavaScript发起

PUT和DELETE分别表示添加资源和删除资源,但是实际上这只是语义上的一种约定,并没有强约束。

CONNECT现在多用于HTTPS和WebSocket。

OPTIONS和TRACE一般用于调试,多数线上服务都不支持。

HTTP Status code (状态码)和 Status text (状态文本)

接下来我们看看response line的状态码和状态文本。常见的状态码有以下几种。

- 1xx: 临时回应,表示客户端请继续。
- 2xx: 请求成功。
 - 。 200: 请求成功。
- 3xx 表示请求的目标有变化,希望客户端进一步处理。
 - 。 301&302: 永久性与临时性跳转。
 - 。 304: 跟客户端缓存没有更新。
- 4xx: 客户端请求错误。
 - 。 403: 无权限。
 - 。 404: 表示请求的页面不存在。
 - 。 418: It's a teapot. 这是一个彩蛋,来自ietf的一个愚人节玩笑。(<u>超文本咖啡壶控制协</u>议)
- 5xx: 服务端请求错误。
 - 500: 服务端错误。
 - 。 503: 服务端暂时性错误,可以一会再试。

对我们前端来说,**1xx**系列的状态码是非常陌生的,原因是**1xx**的状态被浏览器**http**库直接处理掉了,不会让上层应用知晓。

2xx系列的状态最熟悉的就是200,这通常是网页请求成功的标志,也是大家最喜欢的状态码。

3xx系列比较复杂,301和302两个状态表示当前资源已经被转移,只不过一个是永久性转移,一个是临时性转移。实际上301更接近于一种报错,提示客户端下次别来了。

304又是一个每个前端必知必会的状态,产生这个状态的前提是:客户端本地已经有缓存的版本,并且在Request中告诉了服务端,当服务端通过时间或者tag,发现没有更新的时候,就会返回一个不含body的304状态。

HTTP Head (HTTP头)

HTTP头可以看作一个键值对。原则上,HTTP头也是一种数据,我们可以自由定义HTTP头和值。不过在HTTP规范中,规定了一些特殊的HTTP头,我们现在就来了解一下它们。

在HTTP标准中,有完整的请求/响应头规定,这里我们挑几个重点的说一下:

我们先来看看Request Header。

Request Header	规定
Accept	浏览器端接受的格式。
Accept-Encoding:	浏览器端接收的编码方式。
Accept-Language	浏览器端接受的语言,用于服务端判断多语言。
Cache-Control	控制缓存的时效性。
Connection	连接方式,如果是keep-alive,且服务端支持,则会复用连接。
Host	HTTP访问使用的域名。
If-Modified-Since	上次访问时的更改时间,如果服务端认为此时间后自己没有更新,则 会给出304响应。
If-None-Match	次访问时使用的E-Tag,通常是页面的信息摘要,这个比更改时间更准确一些。
User-Agent	客户端标识,因为一些历史原因,这是一笔糊涂账,多数浏览器的这 个字段都十分复杂,区别十分微妙。
Cookie	客户端存储的cookie字符串。

接下来看一下Response Header。

Response Header	规定
Cache-Control	缓存控制,用于通知各级缓存保存的时间,例如max-age=0,表示不要缓存。
Connection	连接类型,Keep-Alive表示复用连接。
Content-Encoding	内容编码方式,通常是gzip。
Content-Length	内容的长度,有利于浏览器判断内容是否已经结束。
Content-Type	内容类型,所有请求网页的都是text/html。
Date	当前的服务器日期。
ETag	页面的信息摘要,用于判断是否需要重新到服务端取回页面。
Expires	过期时间,用于判断下次请求是否需要到服务端取回页面。
Keep-Alive	保持连接不断时需要的一些信息,如timeout=5, max=100。
Last-Modified	页面上次修改的时间。
Server	服务端软件的类型。
Set-Cookie	设置cookie,可以存在多个。
Via	服务端的请求链路,对一些调试场景至关重要的一个头。

这里仅仅列出了我认为比较常见的HTTP头,这些头是我认为前端工程师应该做到不需要查阅,看到就可以知道意思的HTTP头。完整的列表还是请你参考我给出的rfc2616标准。

HTTP Request Body

HTTP请求的body主要用于提交表单场景。实际上,http请求的body是比较自由的,只要浏览器端发送的body服务端认可就可以了。一些常见的body格式是:

- application/json
- application/x-www-form-urlencoded
- multipart/form-data
- text/xml

我们使用html的form标签提交产生的html请求,默认会产生 application/x-www-form-urlencoded 的数据格式,当有文件上传时,则会使用multipart/form-data。

HTTPS

在HTTP协议的基础上,HTTPS和HTTP2规定了更复杂的内容,但是它基本保持了HTTP的设计思想,即:使用上的Request-Response模式。

我们首先来了解下HTTPS。HTTPS有两个作用,一是确定请求的目标服务端身份,而是保证传输的数据不会被网络中间节点窃听或者篡改。

HTTPS的标准也是由RFC规定的,你可以查看它的详情链接:

https://tools.ietf.org/html/rfc2818

HTTPS是使用加密通道来传输HTTP的内容。但是HTTPS首先与服务端建立一条TLS加密通道。 TLS构建于TCP协议之上,它实际上是对传输的内容做一次加密,所以从传输内容上看,HTTPS 跟HTTP没有任何区别。

HTTP2

HTTP2是HTTP1.1的升级版本,你可以查看它的详情链接。

https://tools.ietf.org/html/rfc7540

HTTP2.0 最大的改进有两点,一是支持服务端推送、二是支持TCP连接复用。

服务端推送能够在客户端发送第一个请求到服务端时,提前把一部分内容推送给客户端,放入缓存当中,这可以避免客户端请求顺序带来的并行度不高,从而导致的性能问题。

TCP连接复用,则使用同一个TCP连接来传输多个HTTP请求,避免了TCP连接建立时的三次握手开销,和初建TCP连接时传输窗口小的问题。

Note: 其实很多优化涉及更下层的协议。IP层的分包情况,和物理层的建连时间是需要被考虑的。

结语

在这一节内容中,我们一起学习了浏览器的第一步工作,也就是"浏览器首先使用HTTP协议或HTTPS协议,向服务端请求页面"的这一过程。

在这个过程中,掌握HTTP协议是重中之重。我从一个小实验开始,带你体验了一次完整的HTTP 请求过程。我们一起先分析了HTTP协议的结构。接下来,我分别介绍了HTTP方法、HTTP状态码和状态文本、HTTP Head和HTTP Request Body几个重点需要注意的部分。

最后,我还介绍了HTTPS和HTTP2这两个补充版本,以便你可以更好地熟悉并理解新的特性。

你在工作中,是否已经开始使用HTTPS和HTTP2协议了呢?用到了它们的哪些特性,请留言告诉我吧。

重学前端

每天10分钟, 重构你的前端知识体系

winter 程劭非前手机淘宝前端负责人



精选留言



Carson

്ര 4

现在工作中暂时只使用到 HTTPS。

去年,看到一些公司已经开始着手更新 HTTP2,不少敬佩的前端高手做了分享。

他们利用 HTTP2 服务端推送,以及 TCP 连接复用的特性,把 CSS 和 JS 文件分拆成更小的文件,分批下载。

更小的文件意味着用户可以更快看到页面,以及性能的改善。与此同时,这种处理方式也对生产环境的工具链带来调整和改变。

很有意思的变化。

2019-02-09



徐வ

凸 2

老师真的很喜欢猫呐

2019-02-09



oillie

ம் 1

h2的头部会用哈夫曼编码压缩大小

2019-02-09



yy不会笑

心 0

自己可以扩展补充以下

 > 五层因特网协议栈

 > 长连接与短连接

 > http2.0与http1.1的显著不同点:

 > 强缓存与协商缓存
2019-02-09

 Shaoyao·琚
棒! 已经开始阅览 HTTP3 的文档了图
2019-02-09

老师,浏览器渲染听说有重绘,回流什么的,哪里可以找到这一部分相关资料?

心 0

> DNS查询得到IP

> tcp/ip的并发限制

> get和post的区别

umaru

2019-02-09